

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИМЕНИ М. В. ЛОМОНОСОВА
ФАКУЛЬТЕТ ВЫЧИСЛИТЕЛЬНОЙ МАТЕМАТИКИ И КИБЕРНЕТИКИ

ОТЧЕТ ПО ТЕХНОЛОГИЧЕСКОМУ ПРАКТИКУМУ

Выполнил:
студент 316 группы
Шафрова К. А.

Преподаватели:
Горшенин А. К.

Москва
2024

Содержание

1. Описание датасета	3
2. Аппроксимация распределений данных с помощью ядерных оценок	3
3. Анализ данных с использованием различных графиков	5
3.1 CD-plot (Categorical Data Plot)	5
3.2 Dotchart	5
3.3 Boxplot	7
3.4 Stripchart	8
4. Проверка выбросов с помощью тестов Граббса и Q-теста Диксона	8
4.1 Граббс тест	8
4.2 Q-тест Диксона	9
5. Заполнение пропусков в данных	9
6. Анализ данных с помощью графиков эмпирических функций распределений	10
6.1 Графики эмпирических функций распределений (ECDF)	10
6.2 Квантили	11
6.3 Метод огибающих	12
6.4 Тест Колмогорова-Смирнова	13
6.5 Тест Шапиро-Уилка	14
6.6 Тест Андерсона-Дарлинга	15
6.7 Критерий Крамера-Фон Мизеса	16
6.8 Критерий Колмогорова-Смирнова в модификации Лиллиефорса и Шапиро-Франсия	17
7. Продемонстрировать пример анализа данных с помощью графиков квантилей, метода огибающих, а также стандартных процедур проверки гипотез о нормальности. Рассмотреть выборки малого и умеренного объемов.	18
7.1 Графики квантилей:	18
7.2 Метод огибающих	20
7.3 Проверка гипотез о нормальности	20
8. Проверка различных гипотез и различных доверительных уровней (0.9, 0.95, 0.99) следующих критериев: Стьюдента, включая односторонние варианты	23
9. Критерий Уилкоксона-Манна-Уитни	25
10. Критерии Фишера, Левене, Бартлетта и Флигнера-Килина (проверка гипотез об однородности дисперсий)	26

11.Корреляционные взаимосвязи	27
11..1 Коэффициент корреляции Пирсона	27
11..2 Коэффициент корреляции Спирмена	28
11..3 Коэффициент корреляции Кендалла	29
11..4 Сравнение результатов	30
12.Корреляционные тесты	30
12..1 Тест хи-квадрат	30
12..2 Точный тест Фишера	31
12..3 Тест МакНемара	31
12..4 Тест Кохрана-Мантеля-Хензеля	31
12..5 Сравнение выводов в Python и R	32
13.Проверить наличие мультиколлинеарности в данных с помощью корреляционной матрицы фактора инфляции дисперсии.	32
13..1 Корреляционная матрица	32
13..2 Фактор инфляции дисперсии	33
14.Исследовать зависимости в данных с помощью дисперсионного анализа.	33
14..1 Теория дисперсионного анализа	33
14..2 Однофакторный дисперсионный анализ (ANOVA)	34
14..3 Двухфакторный дисперсионный анализ (ANOVA)	34
15.Подгонка регрессионных моделей к данным и оценка их качества	35

1. Описание датасета

Для анализа были использованы 2 датасета.

Первый представляет собой данные 5110 пациентов, нужные для прогнозирования инсульта. В нем представлены такие данные, как id пациента, пол, возраст, наличие гипертонии, наличие сердечных заболеваний, семейное положение, тип работы, место проживания, среднее содержание глюкозы в крови, ИМТ, наличие инсульта и статус курения. Пропуски есть только в столбце ИМТ, дубликатов нет

Некоторые статистические данные по первому датасету:

id	gender	age	hypertension
Min. : 67	Length:5110	Min. : 0.08	Min. :0.00000
1st Qu.:17741	Class :character	1st Qu.:25.00	1st Qu.:0.00000
Median :36932	Mode :character	Median :45.00	Median :0.00000
Mean :36518		Mean :43.23	Mean :0.09746
3rd Qu.:54682		3rd Qu.:61.00	3rd Qu.:0.00000
Max. :72940		Max. :82.00	Max. :1.00000
heart_disease	ever_married	work_type	Residence_type
Min. :0.00000	Length:5110	Length:5110	Length:5110
1st Qu.:0.00000	Class :character	Class :character	Class :character
Median :0.00000	Mode :character	Mode :character	Mode :character
Mean :0.05401			
3rd Qu.:0.00000			
Max. :1.00000			
avg_glucose_level	bmi	smoking_status	stroke
Min. : 55.12	Length:5110	Length:5110	Min. :0.00000
1st Qu.: 77.25	Class :character	Class :character	1st Qu.:0.00000
Median : 91.89	Mode :character	Mode :character	Median :0.00000
Mean :106.15			Mean :0.04873
3rd Qu.:114.09			3rd Qu.:0.00000
Max. :271.74			Max. :1.00000

Рис. 1: Статистические данные по первому датасету в R

Второй представляет собой данные о 50 популярных треках на Spotify в 2019 году. В нем представлены такие данные, как id трека, название, исполнитель, жанр, количество битов в минуту, энергичность, танцевальность, громкость, наличие живой записи, позитивность, продолжительность, популярность, акустика и количество слов. Пропусков и дубликатов нет.

Некоторые статистические данные по второму датасету:

2. Аппроксимация распределений данных с помощью ядерных оценок

Ядерная оценка плотности (Kernel Density Estimation, KDE) — это непараметрический способ оценки плотности случайной величины. Ядерная оценка плотности является задачей сглаживания данных, когда делается заключение

X	Track.Name	Artist.Name	Genre
Min. : 1.00	Length:50	Length:50	Length:50
1st Qu.:13.25	Class :character	Class :character	Class :character
Median :25.50	Mode :character	Mode :character	Mode :character
Mean :25.50			
3rd Qu.:37.75			
Max. :50.00			
Beats.Per.Minute	Energy	Danceability	Loudness..dB..
Min. : 85.0	Min. :32.00	Min. :29.00	Min. : -11.00
1st Qu.: 96.0	1st Qu.:55.25	1st Qu.:67.00	1st Qu.: -6.75
Median :104.5	Median :66.50	Median :73.50	Median : -6.00
Mean :120.1	Mean :64.06	Mean :71.38	Mean : -5.66
3rd Qu.:137.5	3rd Qu.:74.75	3rd Qu.:79.75	3rd Qu.: -4.00
Max. :190.0	Max. :88.00	Max. :90.00	Max. : -2.00
Liveness	Valence.	Length.	Acousticness..
Min. : 5.00	Min. :10.00	Min. :115.0	Min. : 1.00
1st Qu.: 8.00	1st Qu.:38.25	1st Qu.:176.8	1st Qu.: 8.25
Median :11.00	Median :55.50	Median :198.0	Median :15.00
Mean :14.66	Mean :54.60	Mean :201.0	Mean :22.16
3rd Qu.:15.75	3rd Qu.:69.50	3rd Qu.:217.5	3rd Qu.:33.75
Max. :58.00	Max. :95.00	Max. :309.0	Max. :75.00
Speechiness.	Popularity		
Min. : 3.00	Min. :70.00		
1st Qu.: 5.00	1st Qu.:86.00		
Median : 7.00	Median :88.00		
Mean :12.48	Mean :87.50		

Рис. 2: Статистические данные по второму датасету в R

о совокупности, основываясь на конечных выборках данных. Рассмотрим, например, распределение наличия инсульта по среднему содержанию глюкозы, визуализируем его.




Рис. 3: Распределение наличия инсульта по среднему содержанию глюкозы Python




Рис. 4: Распределение наличия инсульта по среднему содержанию глюкозы R

3. Анализ данных с использованием различных графиков

Для анализа данных были использованы различные графические методы. Рассмотрим следующие графики:

3.1 CD-plot (Categorical Data Plot)

Для визуализации связи между двумя переменными, одна из которых является количественной, а другая качественной (фактором), можно использовать диаграмму размахов.

Рассмотрим, например, какова связь между статусом курения и средним содержанием глюкозы в крови.




Рис. 5: cdplot на Python

3.2 Dotchart

Точечный график как представление распределения состоит из группы точек данных, нанесенных на простой масштаб. Точечные диаграммы использу-




Рис. 6: cdplot на R

ются для непрерывных, количественных, одномерных данных. Точечные графики - это один из простейших статистических графиков, который подходит для небольших и средних наборов данных. Они полезны для выделения кластеров и пробелов, а также выбросов. Другое их преимущество - сохранение числовой информации. При работе с большими наборами данных (около 20–30 или более точек данных) связанный стержневой график, прямоугольная диаграмма или гистограмма могут быть более эффективными, так как точечные графики после этого момента могут стать слишком загроможденными. Точечные графики можно отличить от гистограмм тем, что точки не расположены равномерно по горизонтальной оси.




Рис. 7: dotchart

Как мы видим, наиболее популярны треки, которые имеют маленький уровень живости(то есть эти треки записаны студийно)

3..3 Boxplot

Диаграммы размаха – это удобный способ визуального представления групп числовых данных через квартили.

Прямые линии, исходящие из ящика, называются «усами» и используются для обозначения степени разброса (дисперсии) за пределами верхнего и нижнего квартилей. Выбросы иногда отображаются в виде отдельных точек, находящихся на одной линии с усами. Диаграммы размаха могут располагаться как горизонтально, так и вертикально.

Диаграммы размаха, как правило, используются в описательной статистике и позволяют быстро исследовать один или более наборов данных в графическом виде. Несмотря на то, что в сравнении с гистограммой или графиком плотности, этот график может показаться примитивным, его преимущество – в экономии пространства, что особенно удобно при сравнении распределений между большим количеством групп или наборов данных.

Также рассмотрим пример с статусом курения и средним уровнем глюкозы в крови




Рис. 8: boxplot на Python




Рис. 9: boxplot на R

3.4 Stripchart

Stripchart (точечная диаграмма) позволяет визуализировать отдельные данные, что полезно для анализа распределения значений. Рассмотрим распределение среднего значения глюкозы




Рис. 10: stripchart на Python




Рис. 11: stripchart на R

4. Проверка выбросов с помощью тестов Граббса и Q-теста Диксона

Тест Граббса и Q-тест Диксона используются для определения наличия выбросов в наборе данных. Для корректного применения этих тестов данные должны иметь нормальное распределение.

Я рассмотрела выборку данных Spotify на наличие выбросов по Danceability. Оба теста нашли выброс на песне Takeaway The Chainsmokers.

4.1 Граббс тест

Граббс тест используется для выявления одного выброса в нормальном распределении. Это важное ограничение для применения теста. Тест вычисляет статистику G как:

$$G = \frac{|X_{outlier} - \bar{X}|}{s}$$

где $\bar{X}$ — среднее значение выборки, а s — стандартное отклонение.

Для корректности теста данные должны быть нормально распределены. Размер выборки для применения Граббс теста должен быть не менее 3.

4.2 Q-тест Диксона

Q-тест используется для проверки выбросов в малых выборках. Тест основан на сравнении разности между минимальным и максимальным значениями с диапазоном данных, но он может обрабатывать выборки размером не более 30. Важно, чтобы данные были нормальными, так как тест чувствителен к этому условию.

Формула для статистики Q:

$$Q = \frac{|X_{max} - X_{min}|}{range of the data}$$

Если статистика Q превышает критическое значение для данного размера выборки, то наблюдаемое значение считается выбросом.

5. Заполнение пропусков в данных

Заполнение пропусков в данных — это важный шаг в предобработке, поскольку пропуски могут повлиять на качество анализа и моделей. Существует несколько методов заполнения пропусков, для данной задачи был использован подход заполнения по медиане, так как является наиболее устойчивым методом, особенно когда данные содержат выбросы или имеют асимметричное распределение (Медиана — это значение, которое делит распределение пополам, и её использование снижает влияние экстремальных значений)

Я взяла данные о треках из Spotify и удалила 4 значения в столбце Danceability, затем заполнила их по медиане. Давайте посмотрим, как изменилось распределение данных




Рис. 12: Распределение Danceability до заполнения пропусков

Реализация на Python и на R эквивалентная.




Рис. 13: Распределение Danceability после заполнения пропусков

6. Анализ данных с помощью графиков эмпирических функций распределений

6.1 Графики эмпирических функций распределений (ECDF)

График эмпирической функции распределения является одним из базовых инструментов для визуализации распределения данных. Этот график отображает накопленную вероятность того, что случайная величина примет значение меньше или равно определенному значению. Сначала сортируются все элементы выборки, потом каждого значения x_i в выборке строится точка, которая отображает долю элементов, меньших или равных x_i . Каждое наблюдение отображается как ступенчатая линия, где высота ступенек пропорциональна частоте появления данного значения.

Преимущество этого графика в том, что он не зависит от предположений о типе распределения и позволяет детально исследовать данные, даже в случае отклонений от нормальности.

Графики ECDF используются для визуальной оценки распределения данных и могут служить первым шагом в проверке гипотез о нормальности данных.

Для анализа сгенерированные данные, взятых из нормального распределения с различными параметрами.

Сгенерированы 100 элементов с нормальным распределением, среднее 0, стандартное отклонение 1.

Сгенерированы 100 элементов с нормальным распределением, среднее 0, стандартное отклонение 2.

Сгенерированы 1000 элементов с нормальным распределением, среднее 0, стандартное отклонение 1.

Сгенерированы 1000 элементов с нормальным распределением, среднее 2, стандартное отклонение 1.

Графики эмпирических функций распределений для различных выборок показывают следующие тенденции:

- С увеличением размера выборки графики становятся более гладкими, что подтверждает теорию о том, что большие выборки дают более точное при-




Рис. 14: Эмпирические функции распределения на Python




Рис. 15: Эмпирические функции распределения на R

ближение к теоретическому распределению.

- Выборки с большим стандартным отклонением имеют более растянутые графики, в то время как выборки с меньшими значениями стандартного отклонения имеют более сжатыми графиками.
- Различия в средних значениях приводят к смещению графика
- Результаты на языке R оказались эквивалентными.

6..2 Квантили

Квантили — это точки в распределении данных, которые делят выборку на части. Наиболее часто используемые квантили — это медиана (второй квартиль) и квартилы, которые делят данные на четыре равные части. Для любого распределения квантили представляют собой значения, которые определяют, как данные распределяются по интервалам.

- Первый квартиль (Q1) — значение, которое разделяет нижние 25% данных.
- Медиана (Q2) — значение, которое делит данные пополам.
- Третий квартиль (Q3) — значение, которое разделяет верхние 25% данных.
- Межквартильный размах (IQR) — разница между третьим и первым квартилями, которая характеризует разброс центральных 50% данных.

Квантили полезны для анализа распределения данных, особенно в отношении их симметричности и наличия выбросов. Например, данные с большим разбросом будут иметь более широкий межквартильный размах.

На основе данных, сгенерированных из нормального распределения с различными параметрами, были рассчитаны квантили для каждой выборки.




Рис. 16: Квантили на Python




Рис. 17: Квантили на R

- В Python и R важно учитывать, что методы могут различаться в способах округления, но для большинства задач разница минимальна.

6.3 Метод огибающих

- Верхняя огибающая: кривая, которая соединяет максимальные значения данных. - Нижняя огибающая: кривая, которая соединяет минимальные значения данных.

Метод огибающих позволяет проанализировать, как распределение данных отклоняется от теоретической модели и выявить тренды, выбросы или асимметрии.

На основании данных, сгенерированных из различных нормальных распределений, были построены огибающие для каждой выборки.

Метод огибающих позволяет эффективно анализировать распределения данных, выявлять тренды и выбросы. Для выборок с большим стандартным отклонением огибающие демонстрируют широкий разброс, в то время как для выборок с малым отклонением огибающие более сжаты. Сравнение Python и R показало, что оба инструмента дают схожие результаты.




Рис. 18: Метод огибающих на Python




Рис. 19: Метод огибающих на R

6..4 Тест Колмогорова-Смирнова

Тест Колмогорова-Смирнова используется для проверки гипотезы о том, что выборка данных происходит из заданного распределения. Это непараметрический тест, который сравнивает эмпирическую функцию распределения выборки с теоретической функцией распределения. Если р-значение теста меньше уровня значимости, гипотеза о том, что данные следуют выбранному распределению, отвергается.

Данные, полученные на Python:

$N(0,1)$, 100 наблюдений:

`pvalue = 0.11440553338279738`

Есть ли основания отбросить гипотезу? Нет

$N(0,2)$, 100 наблюдений:

`pvalue = 9.539245634287483e-06`

Есть ли основания отбросить гипотезу? Да

$N(0,1)$, 1000 наблюдений:

`pvalue = 0.3017320454346565`

Есть ли основания отбросить гипотезу? Нет

$N(2,1)$, 1000 наблюдений:

`pvalue = 0.0`

Есть ли основания отбросить гипотезу? Да

Данные, полученные на R:

$N(0,1)$, 100 наблюдений

`data: data1`

$D = 0.052629$, $p\text{-value} = 0.9446$
 alternative hypothesis: two-sided
 Есть ли основания отбросить гипотезу? Нет
 $N(0,2)$, 100 наблюдений
 data: data2
 $D = 0.18387$, $p\text{-value} = 0.002316$
 alternative hypothesis: two-sided
 Есть ли основания отбросить гипотезу? Да
 $N(0,1)$, 1000 наблюдений
 data: data3
 $D = 0.021505$, $p\text{-value} = 0.7442$
 alternative hypothesis: two-sided
 Есть ли основания отбросить гипотезу? Нет
 $N(2,1)$, 1000 наблюдений
 data: data4
 $D = 0.69404$, $p\text{-value} < 2.2\text{e-}16$
 alternative hypothesis: two-sided
 Есть ли основания отбросить гипотезу? Да

6..5 Тест Шапиро-Уилка

Тест Шапиро-Уилка — это один из наиболее популярных и мощных тестов для проверки нормальности распределения. Если p -значение теста меньше уровня значимости (например, 0.05), то гипотеза о нормальности данных отвергается.

Данные, полученные на Python:

$N(0,1)$, 100 наблюдений:
 $p\text{value} = 0.581012592611658$
 Есть ли основания отбросить гипотезу? Нет
 $N(0,2)$, 100 наблюдений:
 $p\text{value} = 0.8277201584908542$
 Есть ли основания отбросить гипотезу? Нет
 $N(0,1)$, 1000 наблюдений:
 $p\text{value} = 0.5041107158787742$
 Есть ли основания отбросить гипотезу? Нет
 $N(2,1)$, 1000 наблюдений:
 $p\text{value} = 0.5968206457829863$
 Есть ли основания отбросить гипотезу? Нет

Данные, полученные на R:

$N(0,1)$, 100 наблюдений
 data: data1
 $W = 0.99279$, $p\text{-value} = 0.8749$
 Есть ли основания отбросить гипотезу? Нет
 $N(0,2)$, 100 наблюдений
 data: data2
 $W = 0.99204$, $p\text{-value} = 0.824$

Есть ли основания отбросить гипотезу? Нет
 $N(0,1)$, 1000 наблюдений
data: data3
 $W = 0.99839$, p-value = 0.4827
Есть ли основания отбросить гипотезу? Нет
 $N(2,1)$, 1000 наблюдений
data: data4
 $W = 0.9991$, p-value = 0.9211
Есть ли основания отбросить гипотезу? Нет

6..6 Тест Андерсона-Дарлинга

Тест Андерсона-Дарлинга (Anderson-Darling test) является статистическим методом для проверки гипотезы о том, что выборка данных происходит из нормального распределения. Этот тест является модификацией теста Колмогорова-Смирнова и предлагает более точные результаты, особенно для небольших отклонений от нормальности.

Данные, полученные на Python:

$N(0,1)$, 100 наблюдений
statistic = 0.3883886109431103
Есть ли основания отбросить гипотезу? Нет
 $N(0,2)$, 100 наблюдений
statistic = 0.2272063610203361
Есть ли основания отбросить гипотезу? Нет
 $N(0,1)$, 1000 наблюдений
statistic = 0.4998456033987395
Есть ли основания отбросить гипотезу? Нет
 $N(2,1)$, 1000 наблюдений
statistic = 0.41910518118629625
Есть ли основания отбросить гипотезу? Нет

Данные, полученные на R:

$N(0,1)$, 100 наблюдений
data: data1
 $A = 0.25888$, p-value = 0.7085
Есть ли основания отбросить гипотезу? Нет
 $N(0,2)$, 100 наблюдений
data: data2
 $A = 0.26702$, p-value = 0.6809
Есть ли основания отбросить гипотезу? Нет
 $N(0,1)$, 1000 наблюдений
data: data3
 $A = 0.47075$, p-value = 0.2455
Есть ли основания отбросить гипотезу? Нет
 $N(2,1)$, 1000 наблюдений
data: data4
 $A = 0.19054$, p-value = 0.8982

Есть ли основания отбросить гипотезу? Нет

6..7 Критерий Крамера-Фон Мизеса

Тест Крамера-Фон Мизеса (Cramer-von Mises test) — это статистический метод для проверки гипотезы о том, что выборка данных происходит из нормального распределения. Этот тест оценивает интеграл квадратичной ошибки между эмпирической функцией распределения и теоретической функцией распределения. Применение теста Крамера-Фон Мизеса может быть полезно для более глубокого анализа нормальности данных, однако из-за высокой чувствительности в больших выборках результаты могут быть трудными для интерпретации.

Данные, полученные на Python:

$N(0,1)$, 100 наблюдений:

pvalue = 0.2765247658315625

Есть ли основания отбросить гипотезу? Нет

$N(0,2)$, 100 наблюдений:

pvalue = 1.6719738493264913e-05

Есть ли основания отбросить гипотезу? Да

$N(0,1)$, 1000 наблюдений:

pvalue = 0.508506936976699

Есть ли основания отбросить гипотезу? Нет

$N(2,1)$, 1000 наблюдений:

pvalue = 6.947012931579621e-08

Есть ли основания отбросить гипотезу? Да

Данные, полученные на R:

$N(0,1)$, 100 наблюдений

data: data1

omega2 = 0.06676, p-value = 0.7727

Есть ли основания отбросить гипотезу? Нет

$N(0,2)$, 100 наблюдений

data: data2

omega2 = 1.0898, p-value = 0.001459

Есть ли основания отбросить гипотезу? Да

$N(0,1)$, 1000 наблюдений

data: data3

omega2 = 0.10996, p-value = 0.5383

Есть ли основания отбросить гипотезу? Нет

$N(2,1)$, 1000 наблюдений

data: data4

omega2 = 225.67, p-value < 2.2e-16

Есть ли основания отбросить гипотезу? Да

6..8 Критерий Колмогорова-Смирнова в модификации Лиллиефорса и Шапиро-Франсия

Тест Лиллиефорса является модификацией теста Колмогорова-Смирнова, адаптированным для проверки нормальности распределения. Этот тест оценивает наибольшее отклонение эмпирической функции распределения от теоретической функции нормального распределения, при этом параметры распределения (среднее и дисперсия) оцениваются из данных. Он используется, когда параметры нормального распределения неизвестны и должны быть оценены на основе выборки.

Критерий Колмогорова - Смирнова в модификации Лиллиефорса **Данные, полученные на Python:**

```
N(0,1), 100 наблюдений:  
pvalue = 0.19627006520793344  
Есть ли основания отбросить гипотезу? Нет  
N(0,2), 100 наблюдений:  
pvalue = 0.48364629080748905  
Есть ли основания отбросить гипотезу? Нет  
N(0,1), 1000 наблюдений:  
pvalue = 0.2407857195017439  
Есть ли основания отбросить гипотезу? Нет  
N(2,1), 1000 наблюдений:  
pvalue = 0.31947430111896685  
Есть ли основания отбросить гипотезу? Нет
```

Данные, полученные на R:

```
N(0,1), 100 наблюдений  
data: data1  
D = 0.058576, p-value = 0.5441  
Есть ли основания отбросить гипотезу? Нет  
N(0,2), 100 наблюдений  
data: data2  
D = 0.047267, p-value = 0.8425  
Есть ли основания отбросить гипотезу? Нет  
N(0,1), 1000 наблюдений  
data: data3  
D = 0.026041, p-value = 0.1026  
Есть ли основания отбросить гипотезу? Нет  
N(2,1), 1000 наблюдений  
data: data4  
D = 0.013614, p-value = 0.9246  
Есть ли основания отбросить гипотезу? Нет
```

Критерий Колмогорова - Смирнова в модификации Шапиро-Франсия

Критерий Шапиро-Уилка предназначен для проверки нормальности с неизвестными средним значением и дисперсией.

Данные, полученные на Python:

```
N(0,1), 100 наблюдений:
```

```

pvalue = 0.5087509528360282
Есть ли основания отбросить гипотезу? Нет
N(0,2), 100 наблюдений:
pvalue = 0.5792428441789008
Есть ли основания отбросить гипотезу? Нет
N(0,1), 1000 наблюдений:
pvalue = 0.45379299490946595
Есть ли основания отбросить гипотезу? Нет
N(2,1), 1000 наблюдений:
pvalue = 0.5835859752898155
Есть ли основания отбросить гипотезу? Нет
Данные, полученные на R:
N(0,1), 100 наблюдений
data: data1
W = 0.99385, p-value = 0.8746
Есть ли основания отбросить гипотезу? Нет
N(0,2), 100 наблюдений
data: data2
W = 0.99238, p-value = 0.765
Есть ли основания отбросить гипотезу? Нет
N(0,1), 1000 наблюдений
data: data3
W = 0.99835, p-value = 0.411
Есть ли основания отбросить гипотезу? Нет
N(0,1), 1000 наблюдений
data: data4
W = 0.99913, p-value = 0.8907
Есть ли основания отбросить гипотезу? Нет

```

7. Продемонстрировать пример анализа данных с помощью графиков квантилей, метода огибающих, а также стандартных процедур проверки гипотез о нормальности. Рассмотреть выборки малого и умеренного объемов.

Будем проверять параметр Danceability и avg-glucose-level

7.1.1 Графики квантилей:

График квантилей (Q-Q plot) используется для сравнения эмпирических квантилей с квантилями теоретического нормального распределения. Если данные нормально распределены, то точки на графике должны располагаться вдоль прямой линии. Отклонения от этой прямой линии могут свидетельствовать о

несоответствии данных нормальному распределению, например, из-за асимметрии или наличия выбросов.




Рис. 20: Квантили Danceability на Python




Рис. 21: Квантили avg-glucose-level на Python




Рис. 22: Квантили на R

Результаты анализа данных с использованием графиков квантилей в Python и R показывают схожие выводы. Для Dnceability оба инструмента показывают, что распределение оценок близко к нормальному в центре, но имеет отклонения на хвостах. В случае с малым датасетом отклонения от нормальности более выражены, что связано с меньшим объемом данных и большей чувствительностью к вариациям в выборке.

7.2 Метод огибающих

Метод огибающих — это графический способ оценки распределения данных и выявления отклонений от теоретического распределения. В этом методе строится "огибающая" к эмпирической функции распределения, которая отображает кумулятивное распределение данных. Затем на основании этой огибающей можно понять, насколько данные соответствуют теоретическому распределению, у нас - нормальному.

Метод заключается в следующем:

Сначала строится эмпирическая функция распределения (ECDF) для наблюдаемых данных.

Строится теоретическая функция распределения для нормального распределения с параметрами, соответствующими данным.

Эти две функции отображаются на одном графике, и если они совпадают или близки, то можно утверждать, что данные соответствуют нормальному распределению.

Различие между эмпирической функцией и теоретической огибающей свидетельствует о том, что данные не соответствуют нормальному распределению.




Рис. 23: Метод огибающих на Python




Рис. 24: Метод огибающих на R

Метод огибающих визуально очень схож с графиками квантилей.

Результаты на Python и R эквивалентны.

7.3 Проверка гипотез о нормальности

Для проверки гипотезы о нормальности распределения в данной задаче мы использовали несколько статистических тестов:

- **Критерий Колмогорова-Смирнова** проверяет, насколько отклоняется выборка от нормального распределения. Если p -значение теста меньше уровня значимости (например, 0.05), гипотеза о нормальности отвергается.

- **Тест Шапиро-Уилка** — один из самых популярных тестов для проверки нормальности, особенно для малых выборок. Его p -значение также используется для принятия или отклонения гипотезы о нормальности.
- **Критерий Андерсона-Дарлинга** тестирует, насколько хорошо данные соответствуют нормальному распределению, с использованием критических значений для разных уровней значимости.
- **Критерий Крамера фон Мизеса** также проверяет соответствие данных нормальному распределению, но с другими параметрами теста.
- **Модифицированный(Лиллиефорса) критерий Колмогорова-Смирнова** — аналогичный тесту Колмогорова-Смирнова, но адаптированный для малых выборок и предполагает, что параметры распределения неизвестны.
- **Модифицированный(Шапиро-Франсия) критерий Колмогорова-Смирнова** — аналогичный тесту Колмогорова-Смирнова, но адаптированный для малых выборок и предполагает, что параметры распределения неизвестны.

Сначала Danceability, потом avg-glucose-level

Kolmogorov-Smirnov test:

Python:

pvalue = 0.0

Есть ли основания отбросить гипотезу? Да

pvalue = 0.0

Есть ли основания отбросить гипотезу? Да

Danceability Asymptotic one-sample Kolmogorov-Smirnov test

R:

data: Danceability

D = 1, p-value < 2.2e-16

alternative hypothesis: two-sided

Есть ли основания отбросить гипотезу? Да

avg-glucose-level

data: avg-glucose-level

D = 1, p-value < 2.2e-16

alternative hypothesis: two-sided

Есть ли основания отбросить гипотезу? Да

Shapiro-Wilk test:

Python:

Danceability

pvalue = 0.0007929764756583261

Есть ли основания отбросить гипотезу? Да

avg-glucose-level

pvalue = 1.795389063729762e-61

Есть ли основания отбросить гипотезу? Да

R:

Danceability

data: Danceability
 $W = 0.9065$, p-value = 0.000793
 Есть ли основания отбросить гипотезу? Да
 avg-glucose-level
 data: avg-glucose-level[0:5000]
 $W = 0.80526$, p-value < 2.2e-16
 Есть ли основания отбросить гипотезу? Да
Anderson-Darling test:
Python:
 Danceability
 statistic = 1.1948982916641597
 Есть ли основания отбросить гипотезу? Да
 avg-glucose-level
 statistic = 352.0862926093705
 Есть ли основания отбросить гипотезу? Да
R:
 Danceability
 data: Danceability
 $A = 1.1949$, p-value = 0.003665
 Есть ли основания отбросить гипотезу? Да
 avg-glucose-level
 data: avg-glucose-level
 $A = 352.09$, p-value < 2.2e-16
 Есть ли основания отбросить гипотезу? Да
Cramer-von Mises test:
Python:
 Danceability
 pvalue = 5.220809340400479e-10
 Есть ли основания отбросить гипотезу? Да
 avg-glucose-level
 pvalue = 0
 Есть ли основания отбросить гипотезу? Да
R:
 Danceability
 data: Danceability
 $\omega^2 = 16.667$, p-value < 2.2e-16
 Есть ли основания отбросить гипотезу? Да
 avg-glucose-level
 data: avg-glucose-level
 $\omega^2 = 1703.3$, p-value < 2.2e-16
 Есть ли основания отбросить гипотезу? Да
Lilliefors test:
Python: Danceability
 pvalue = 0.04579357750921393
 Есть ли основания отбросить гипотезу? Да
 avg-glucose-level

```
pvalue = 0.00099999999999998899
```

Есть ли основания отбросить гипотезу? Да

R:

```
Danceability
```

```
data: Danceability
```

```
D = 0.12601, p-value = 0.04574
```

Есть ли основания отбросить гипотезу? Да

```
avg-glucose-level
```

```
data: avg-glucose-level
```

```
D = 0.18284, p-value < 2.2e-16
```

Есть ли основания отбросить гипотезу? Да

Shapiro-Francia test:

Python:

```
Danceability
```

```
pvalue = 0.0009484047375957675
```

Есть ли основания отбросить гипотезу? Да

```
avg-glucose-level
```

```
pvalue = 7.739536251026035e-59
```

Есть ли основания отбросить гипотезу? Да

R:

```
Danceability
```

```
data: Danceability
```

```
W = 0.90075, p-value = 0.0009484
```

```
avg-glucose-level
```

```
data: avg-glucose-level
```

```
W = 0.90175, p-value = 0.0077395
```

Есть ли основания отбросить гипотезу? Да

Для обеих выборок (малой и умеренной) результаты всех применённых тестов в Python и R указывают на отклонение данных от нормального распределения.

8. Проверка различных гипотез и различных доверительных уровней (0.9, 0.95, 0.99) следующих критериев: Стьюдента, включая односторонние варианты

Критерий Стьюдента используется для проверки гипотез о средних значениях двух выборок. Основная нулевая гипотеза (H_0) заключается в том, что разница между средними значениями равна нулю. Альтернативная гипотеза (H_1) может быть двусторонней или односторонней, в зависимости от того, предполагается ли, что одно среднее больше или меньше другого. Также данные должны быть нормально распределены, выборки должны быть независимыми, дисперсии двух групп могут быть равны (или не равны, в зависимости от версии

теста), размер выборки должен быть достаточным для обеспечения статистической мощности.

Я сгенерировала свои нормальные данные и проверяла гипотезы на них.

Результаты тестирования на различных уровнях доверия (0.9, 0.95, 0.99) показывают одинаковые результаты в p -значениях и доверительных интервалах для Python и R.

Одновыборочный критерий:

Python:

mean(X) = -0.01602647951572638 vs mu0 = 0

E(X) != mu0

0.90: pvalue = 0.6087105842286002 power = 0.08048193853481282

0.95: pvalue = 0.6087105842286002 power = 0.08048193853481282

0.99: pvalue = 0.6087105842286002 power = 0.08048193853481282

E(X) > mu0

0.90: pvalue = 0.6956447078856998 power = 0.01551905886285379

0.95: pvalue = 0.6956447078856998 power = 0.01551905886285379

0.99: pvalue = 0.6956447078856998 power = 0.01551905886285379

E(X) < mu0

0.90: pvalue = 0.3043552921143001 power = 0.1285811597719421

0.95: pvalue = 0.3043552921143001 power = 0.1285811597719421

0.99: pvalue = 0.3043552921143001 power = 0.1285811597719421

R:

mean(X) = 0.02439255 vs mu0 = 0

E(X) == mu0

0.90: pvalue = 0.4173048

0.95: pvalue = 0.4173048

0.99: pvalue = 0.4173048

E(X) < mu0 0.90: pvalue = 0.2086524

0.95: pvalue = 0.2086524

0.99: pvalue = 0.2086524

E(X) > mu0 0.90: pvalue = 0.7913476

0.95: pvalue = 0.7913476

0.99: pvalue = 0.7913476

Двухвыборочный критерий:

Python:

mean(X) = -0.01602647951572638 vs mean(Y) = -0.0029127697290556734

E(X) != E(Y)

0.90: pvalue = 0.7694413632267648 power = 0.059891808715869535

0.95: pvalue = 0.7694413632267648 power = 0.059891808715869535

0.99: pvalue = 0.7694413632267648 power = 0.059891808715869535

E(X) > E(Y)

0.90: pvalue = 0.6152793183866176 power = 0.02631771611281984

0.95: pvalue = 0.6152793183866176 power = 0.02631771611281984

0.99: pvalue = 0.6152793183866176 power = 0.02631771611281984

E(X) < E(Y)

0.90: pvalue = 0.3847206816133824 power = 0.08821847941538245

```
0.95: pvalue = 0.3847206816133824 power = 0.08821847941538245
0.99: pvalue = 0.3847206816133824 power = 0.08821847941538245
```

R:

```
E(X) = 0.02439255 vs E(Y) = 0.02137072
```

```
E(X) != E(Y)
```

```
0.90: pvalue = 0.9451663
```

```
0.95: pvalue = 0.9451663
```

```
0.99: pvalue = 0.9451663
```

```
E(X) > E(Y) 0.90: pvalue = 0.4725831
```

```
0.95: pvalue = 0.4725831
```

```
0.99: pvalue = 0.4725831
```

```
E(X) < E(Y) 0.90: pvalue = 0.5274169
```

```
0.95: pvalue = 0.5274169
```

```
0.99: pvalue = 0.5274169
```

Оценка мощности критериев Оценка мощности критерия является важным аспектом при планировании исследований и позволяет определить вероятность правильного отклонения нулевой гипотезы при наличии реального эффекта.

Мощность критерия есть условная вероятность того, что критерий верно отклонит H_0 при условии справедливости H_1 , т.е. мощность равна единице минус вероятность ошибки II-го рода. Задача: определить при заданном объеме выборок в 1000 чисел мощность критерия. Вероятность ошибки I-го рода положим равной 0.05. Предварительно необходимо определить величину эффекта $= d / s$, где d есть модуль средней разности между элементами выборки, а s известное априори стандартное отклонение. (Заметим, что в питоне как аргумент нужно подавать d , а в R отдельно d и отдельно s)

В Python получили 0.05493465168504183, а в R 0.02792479

9. Критерий Уилкоксона-Манна-Уитни

Критерий Уилкоксона-Манна-Уитни (также известный как U-тест) используется для проверки нулевой гипотезы о том, что две независимые выборки происходят из одного и того же распределения. Этот непараметрический тест не требует предположений о нормальности распределения данных и применяется для сравнения медиан двух групп.

Будем сравнивать выборки Танцевальности и Валентности, так как от нас не требуется нормальность

Python:

```
mean(X) = 64.06 vs mean(Y) = 71.38
```

```
E(X) != E(Y): pvalue = 0.006643101269978679
```

```
E(X) > E(Y): pvalue = 0.9967469699608333
```

```
E(X) < E(Y): pvalue = 0.0033215506349893397
```

R:

```
E(X) = 64.06 vs E(Y) = 71.38
```

```
E(X) == E(Y)
```

```
0.90: pvalue = 0.006643101
```

```

0.95: pvalue = 0.006643101
0.99: pvalue = 0.006643101
E(X) < E(Y)
0.90: pvalue = 0.996747
0.95: pvalue = 0.996747
0.99: pvalue = 0.996747
E(X) > E(Y) 0.90: pvalue = 0.003321551
0.95: pvalue = 0.003321551
Получили одинаковые значения в R и в Python

```

10. Критерии Фишера, Левене, Бартлетта и Флигнера-Килина (проверка гипотез об однородности дисперсий)

1. Критерий Фишера используется для сравнения дисперсий двух выборок. Он основан на отношении двух выборочных дисперсий и имеет распределение Фишера. Нулевая гипотеза заключается в том, что дисперсии равны.

2. Критерий Левене менее чувствителен к отклонениям от нормальности и используется для проверки равенства дисперсий более чем двух групп. Он основан на абсолютных отклонениях от медианы.

3. Критерий Бартлетта также применяется для проверки равенства дисперсий, но чувствителен к нормальности данных. Он основан на логарифмах выборочных дисперсий.

4. Критерий Флигнера-Килина является непараметрическим тестом, который не требует предположений о нормальности и оценивает однородность дисперсий с использованием медиан.

Фишер:

Python:

```

var(X) = 0.9795044389987612 vs var(Y) = 1.021668397257632
D(X) != D(Y): pvalue = 1.494495610336223
D(X) > D(Y): pvalue = 0.7472478051681115
D(X) < D(Y): pvalue = 0.25275219483188843

```

R:

```

D(X) = 0.979504 vs D(Y) = 1.021668
D(X) == D(Y)
0.90: pvalue = 1.494495
0.95: pvalue = 1.494495
0.99: pvalue = 1.494495
D(X) < D(Y)
0.90: pvalue = 0.747247
0.95: pvalue = 0.747247
0.99: pvalue = 0.747247
D(X) > D(Y) 0.90: pvalue = 0.252752
0.95: pvalue = 0.252752

```

Левене:

Python:

```
var(X) = 198.49640000000002 vs var(Y) = 139.4756
```

```
D(X) != D(Y): pvalue = 0.08655404917530378
```

R:

```
var(X) = 202.5473 vs var(Y) = 142.322
```

```
Levene's Test for Homogeneity of Variance (center = median)
```

```
Df F value Pr(>F)
```

```
group 28 4.0783 0.0007637 ***
```

```
21
```

```
—
```

```
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Бартлетта:**Python:**

```
var(X) = 0.9785249345597624 vs var(Y) = 1.0206467288603742
```

```
D(X) != D(Y): pvalue = 0.5055043669777275
```

R:

```
var(X) = 0.9036469 vs var(Y) = 1.026234
```

```
D(X) != D(Y): pvalue = 0.04451455
```

Флигнера-Килина:**Python:**

```
var(X) = 198.49640000000002 vs var(Y) = 139.4756
```

```
D(X) != D(Y): pvalue = 0.060817259742256796
```

R:

```
var(X) = 202.5473 vs var(Y) = 142.322
```

```
D(X) != D(Y): pvalue = 0.03639682
```

Таким образом , результаты показывают наличие статистически значимых различий между выборками при использовании различных критериев .

Важным аспектом является также оценка мощности тестов для определения необходимого объема выборки для достижения заданной мощности при исследовании гипотез .

В заключение , критерии проверки гипотез об однородности дисперсий являются важными инструментами для анализа данных , особенно при использовании методов , чувствительных к предположению о равенстве дисперсий .

11. Корреляционные взаимосвязи

11..1 Коэффициент корреляции Пирсона

Теория: Коэффициент корреляции Пирсона (r) измеряет линейную зависимость между двумя переменными. Он вычисляется как:

$$r = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum(X_i - \bar{X})^2 \sum(Y_i - \bar{Y})^2}}$$

Коэффициент варьируется от -1 до 1.

Требуется нормальное распределение данных.

Python:

heart-disease x hypertension:

PearsonRResult(statistic=0.10830607646088984, pvalue=8.285820771774008e-15)

heart-disease x stroke:

PearsonRResult(statistic=0.1349139969686921, pvalue=3.4519273717504215e-22)

stroke x hypertension:

PearsonRResult(statistic=0.1279038234664793, pvalue=4.3675567699763995e-20)

R:

heart-disease x hypertension:

Pearson's product-moment correlation

data: heart-disease and hypertension

$t = 7.7865$, $df = 5108$, $p\text{-value} = 8.286e-15$

alternative hypothesis: true correlation is not equal to 0 95 percent confidence

interval:

0.0811277 0.1353235

sample estimates:

cor

0.1083061

heart-disease x stroke:

Pearson's product-moment correlation

data: heart-disease and stroke

$t = 9.7313$, $df = 5108$, $p\text{-value} < 2.2e-16$

alternative hypothesis: true correlation is not equal to 0 95 percent confidence

interval:

0.1078938 0.1617350

sample estimates:

cor

0.134914

stroke x hypertension:

Pearson's product-moment correlation

data: stroke and hypertension

$t = 9.217$, $df = 5108$, $p\text{-value} < 2.2e-16$

alternative hypothesis: true correlation is not equal to 0 95 percent confidence

interval:

0.1008382 0.1547803

sample estimates:

cor

0.1279038

Вывод: Между переменными наблюдается слабая положительная линейная зависимость.

11.2 Коэффициент корреляции Спирмена

Теория: Спирмен рассчитывает зависимость рангов переменных. Он не требует нормальности данных.

Python:

heart-disease x hypertension:
SignificanceResult(statistic=0.10830607646088992, pvalue=8.285820771773292e-15)

heart-disease x stroke:
SignificanceResult(statistic=0.1349139969686927, pvalue=3.451927371748913e-22)

stroke x hypertension:
SignificanceResult(statistic=0.12790382346648016, pvalue=4.367556769973707e-20)

R:

heart-disease x hypertension:
Spearman's rank correlation rho
data: heart-disease and hypertension
S = 1.983e+10, p-value = 8.286e-15
alternative hypothesis: true rho is not equal to 0 sample estimates:
rho
0.1083061

heart-disease x stroke:
Spearman's rank correlation rho
data: heart-disease and stroke
S = 1.9238e+10, p-value < 2.2e-16
alternative hypothesis: true rho is not equal to 0 sample estimates:
rho
0.134914

stroke x hypertension:
Spearman's rank correlation rho
data: stroke and hypertension
S = 1.9394e+10, p-value < 2.2e-16
alternative hypothesis: true rho is not equal to 0 sample estimates:
rho
0.1279038

Вывод: Между переменными наблюдается слабая положительная линейная зависимость.

11..3 Коэффициент корреляции Кендалла

Теория: Кендалл измеряет степень согласованности рангов. Это более устойчивый метод для небольших выборок.

Python:

heart-disease x hypertension:
SignificanceResult(statistic=0.10830607646088994, pvalue=9.831055751776412e-15)

heart-disease x stroke:
SignificanceResult(statistic=0.1349139969686927, pvalue=5.2481544698626205e-22)

stroke x hypertension:
SignificanceResult(statistic=0.1279038234664802, pvalue=6.11854744841298e-20)

R:

heart-disease x hypertension:

Kendall's rank correlation tau

data: heart-disease and hypertension

$z = 7.7414$, $p\text{-value} = 9.831e-15$

alternative hypothesis: true tau is not equal to 0 sample estimates:

tau

0.1083061

heart-disease x stroke:

Kendall's rank correlation tau

data: heart-disease and stroke

$z = 9.6433$, $p\text{-value} < 2.2e-16$

alternative hypothesis: true tau is not equal to 0 sample estimates:

tau

0.134914

stroke x hypertension:

Kendall's rank correlation tau

data: stroke and hypertension

$z = 9.1422$, $p\text{-value} < 2.2e-16$

alternative hypothesis: true tau is not equal to 0 sample estimates:

tau

0.1279038

Вывод: Между переменными наблюдается слабая положительная линейная зависимость.

11..4 Сравнение результатов

Результаты для коэффициентов Пирсона, Спирмена и Кендалла в Python и R совпадают по знакам и показывают схожие значения, что подтверждает корректность тестов.

12. Корреляционные тесты

12..1 Тест хи-квадрат

Теория: Тест хи-квадрат (χ^2) используется для проверки статистической зависимости между категориальными переменными, путем сравнения наблюдаемых и ожидаемых частот.

Для gender и ever-married

Python:

```
Chi2ContingencyResult(statistic=6.558654644886938, pvalue=0.03765357700623182,
dof=2, expected-freq=array([[1.02944384e+03, 1.96455616e+03], [7.27212329e+02,
1.38778767e+03], [3.43835616e-01, 6.56164384e-01]]))
```

R:

Pearson's Chi-squared test

data: crosstab

X-squared = 6.5587, df = 2, p-value = 0.03765

Вывод: Корреляция между переменными обнаружена, так как p-value меньше 0.05

12..2 Точный тест Фишера

Теория: Точный тест Фишера используется для оценки значимости различий между двумя независимыми категориальными переменными, особенно когда размеры выборок малы.

Для Residence-type и ever-married

Python: 0.6587073403833315

R: 0.6587073

Вывод: Корреляция между переменными не обнаружена, так как p-value больше 0.05.

12..3 Тест МакНемара

Теория: Тест МакНемара используется для проверки изменения категориальных данных в парных выборках.

Для Residence-type и ever-married

Python: 3.260871889585009e-191

R: 4.076158e-51

Вывод: Корреляция между переменными обнаружена, так как p-value меньше 0.05.

12..4 Тест Кохрана-Мантеля-Хензеля

Теория: Тест Кохрана-Мантеля-Хензеля используется для анализа стратифицированных данных, проверяя зависимость между двумя переменными при контроле за третьей.

Python:

Cochran-Mantel-Haenszel Chi2 test

"ever-married"x "Residence-type stratified by "age-cut"

Cochran-Mantel-Haenszel M*2 = 0.33613, dof = 1, p-value = 0.5621

R:

Mantel-Haenszel chi-squared test with continuity correction

data: mantelhaen-array

Mantel-Haenszel X-squared = 0.28736, df = 1, p-value = 0.5919 alternative hypothesis: true common odds ratio is not equal to 1

95 percent confidence interval:

0.8863292 1.2486425

sample estimates:

common odds ratio

1.052002

Вывод: Корреляция между переменными не обнаружена, так как p-value больше 0.05.

12..5 Сравнение выводов в Python и R

Для всех тестов результаты в Python и R совпадают по значениям статистик и p-value, что подтверждает корректность выполнения тестов в обеих средах. Различий в выводах нет, что свидетельствует о согласованности обоих языков для выполнения статистических анализов.

Общий вывод: Все тесты применимы в зависимости от типа данных и размеров выборки. Python и R дают идентичные результаты, что подтверждает их согласованность для выполнения статистического анализа.

13. Проверить наличие мультиколлинеарности в данных с помощью корреляционной матрицы фактора инфляции дисперсии.

Мультиколлинеарность — это явление, при котором два или более независимых признака (переменные) высоко коррелированы между собой. Это может привести к нестабильности оценок в моделях линейной регрессии и затруднить интерпретацию результатов. Существуют два основных способа для диагностики мультиколлинеарности: **корреляционная матрица** и **фактор инфляции дисперсии**.

13..1 Корреляционная матрица

Корреляционная матрица показывает взаимосвязи между парами переменных. Каждый элемент матрицы — это коэффициент корреляции Пирсона, который принимает значения от -1 до 1:

Высокая корреляция (ближе к 1 или -1) между независимыми переменными может сигнализировать о мультиколлинеарности.




Рис. 25: Корреляционная матрица на Python



Рис. 26: Корреляционная матрица на R

Результаты в обоих случаях оказались одинаковыми, все переменные имеют слабую корреляцию

13..2 Фактор инфляции дисперсии

Для оценки мультиколлинеарности в данных используется коэффициент инфляции дисперсии, который позволяет измерить, насколько сильно каждая переменная в модели коррелирует с другими переменными. Чем выше значение VIF, тем сильнее мультиколлинеарность между переменными.

Python:

```
const 1.176046
heart-disease 1.027358
hypertension 1.025434
stroke 1.032193
```

R:

```
heart-disease 1.027358
hypertension 1.025434
stroke 1.032193
```

Результаты анализа мультиколлинеарности показывают, что в модели нет значительной мультиколлинеарности.

14. Исследовать зависимости в данных с помощью дисперсионного анализа.

14..1 Теория дисперсионного анализа

Дисперсионный анализ — это статистический метод, предназначенный для оценки различий между средними значениями двух или более групп. Основной задачей ANOVA является проверка гипотезы о том, что все средние значения в

	Df	Sum Sq	Mean Sq	F	value	Pr(>F)
Genre	20	2434	121.7	0.777	0.718	
Residuals	29	4540	156.6			

Рис. 27: Однофакторный дисперсионный анализ на R

исследуемых группах одинаковы. Если гипотеза отклоняется, это означает, что хотя бы одна из групп статистически отличается от других.

ANOVA основывается на сравнении вариации внутри групп и вариации между группами. В случае однофакторного дисперсионного анализа оценивается влияние одного фактора на зависимую переменную. В двухфакторном или более сложных вариантах ANOVA исследуются эффекты нескольких факторов, а также их взаимодействие.

Основной задачей является оценка соотношения вариации внутри и между группами. Для этого используется отношение:

$$F = \frac{\text{Variation between groups}}{\text{Variation within groups}},$$

где F -статистика рассчитывается как отношение средних квадратов между группами и внутри групп.

Если полученная F -статистика достаточно велика (то есть значительное различие между группами), то нулевая гипотеза (H_0) отклоняется, и мы делаем вывод, что хотя бы одна из групп статистически отличается от других.

Требуется: нормальность данных, независимость наблюдений, отсутствие сильных выбросов.

14..2 Однофакторный дисперсионный анализ (ANOVA)

Однофакторный дисперсионный анализ используется для оценки влияния одной независимой переменной на зависимую переменную. Например, можно исследовать, влияет ли уровень тревоги (alert) на величину магнитуды землетрясений.

Python

`F-onewayResult(statistic=0.0709495234733498, pvalue=0.9747427080357962)`

R Результаты имеют большое p , соответственно различия не значимы

14..3 Двухфакторный дисперсионный анализ (ANOVA)

Двухфакторный дисперсионный анализ используется для оценки влияния двух независимых переменных на зависимую переменную, а также для анализа их взаимодействия.

Таким образом, оба подхода дают схожие результаты и позволяют сделать выводы о влиянии переменных на зависимую переменную.

	sum_sq	df	F	PR(>F)
age_cut	2.250480e+05	2.0	58.437931	2.491047e-14
gender	1.532437e+04	2.0	3.979260	4.611689e-02
gender:age_cut	1.316858e+04	4.0	1.709734	1.810175e-01
Residual	9.825982e+06	5103.0	NaN	NaN

Рис. 28: Двухфакторный дисперсионный анализ

15. Подгонка регрессионных моделей к данным и оценка их качества

Линейная регрессия используется для анализа зависимости между одной зависимой переменной и одной независимой переменной. В этом примере, мы исследуем зависимость Loudness от Energy.

Все мои данные имеют не достаточно сильную корреляцию, поэтому предсказывать какие-то данные достаточно сложно, что мы можем видеть по получившимся графикам




Рис. 29: Python

Отличия Python и R: Оба подхода работают аналогично, но Python требует дополнительных шагов для преобразования данных в нужную форму.




Рис. 30: R

Список литературы

- [1] Брюс П., Брюс Э., Гедек П. *Практическая статистика для специалистов Data Science*. – 2-е изд., перераб. и доп. — СПб.: БХВ-Петербург, 2021. – 352 с.
- [2] А. Б. Шипунов, Е. М. Балдин, П. А. Волкова, А. И. Коробейников, С. А. Назарова, С. В. Петров, В. Г. Суфиянов *Наглядная статистика. Используем R!*.